Fakultet elektrotehnike, računarstva i informacijskih tehnologija

Detekcija upale pluća iz rendgenskih snimaka

Luka Idžanović

1.6.2026.

Sadržaj

1. Uvod 2
2. Skup podataka i predobrada podataka 2
3. Implementacija 3
4. Evaluacija modela 5
4.1 Rezultati modela 6
5. Demonstracija rada 10
6. Zaključak 11
7. Literatura 11

1. Uvod

Upala pluća je zarazna bolest donjeg dijela dišnog sustava koja nastaje kada bakterije, virusi ili gljivice napadaju pluća te dovode do upale, odnosno odgovora kojim se ljudsko tijelo brani od infekcija uzrokovanih drugim tijelima. Upala pluća može se javiti u svim dobnim skupinama, od novorođenačke, pa sve do starije životne dobi. Upala pluća u medicinskom rječniku naziva se pneumonija. Početak upale pluća može biti nagao ili postepen, ovisno o uzročniku upale pluća. Bolest je i danas jedan od vodećih uzroka smrtnosti među zaraznim bolestima diljem svijeta, napose kod djece mlađe od pet godina i starijih osoba. Primarna metoda za dijagnostiku upale pluća u kliničkoj praksi je radiografija prsnog koša, odnosno standardna rendgenska snimka (X-ray). Međutim, interpretacija ovih snimki zahtijeva visoku stručnost radiologa, pri čemu su vizualni znakovi često suptilni, preklapajući se s drugim pulmonalnim stanjima, što otvara prostor za ljudsku pogrešku ili previde uslijed zamora sustava.

Glavni cilj ovog projekta je rješavanje problema otežanog raspoznavanja upale pluća preko rendgenskih uzoraka. Razvojem računalnog sustava koji može automatski, s visokom točnošću i u nekoliko sekundi analizirati X-ray snimku, pruža se snažan alat. Ovakav sustav može poslužiti kao "drugo mišljenje" liječnicima opće prakse, ubrzavajući trijažni postupak i omogućujući ranije uvođenje antibiotske ili potporne terapije, čime se izravno utječe na smanjenje stope smrtnosti.

U ovom radu implementiran je sustav računalnog vida temeljen na dubokom učenju (*engl. Deep Learning*). Okosnicu sustava čini konvolucijska neuronska mreža. Umjesto treniranja cijele nove mreže, korišten je predtrenirani model na masivnom skupu podataka (*EfficientNet*) te je fino podešen (*engl. fine-tuning*) za specifične morfološke značajke medicinskih X-ray snimki. Kako bi se izbjegao efekt "crne kutije“, koji je česta kočnica implementacije u medicini, integriran je algoritam *Grad-CAM* za vizualno označavanje regija pluća koji su potaknuli model na donošenje odluke. Osim *EfficientNet* modela, za usporedbu će se koristiti i *VGG-16* predtrenirani model čije će se performanse ujedno i usporediti sa već spomenutim modelom.

2. Skup podataka i predobrada podataka

Za potrebe ovog zadatka korištena je kombinacija dva javno dostupna skupa podataka. Rendgenske snimke prvog skupa podataka predstavljaju snimke prsnog koša pedijatrijskih pacijenata iz Medicinskog centra za žene i djecu Guangzho. Sve rendgenske snimke prsnog koša provedene su kao dio rutinske kliničke skrbi pacijenata. *„Za analizu rendgenskih snimaka prsnog koša, sve rendgenske snimke prsnog koša isprva su pregledane radi kontrole kvalitete uklanjanjem svih snimaka niske kvalitete ili nečitljivih snimaka. Dijagnoze za snimke zatim su ocijenila dva stručna liječnika prije nego što su odobrene za obuku sustava umjetne inteligencije. Kako bi se uzele u obzir sve pogreške u ocjenjivanju, skup za evaluaciju provjerio je i treći stručnjak.“*[1]. Drugi skup rendgenskih slika potječe iz Radiološke zajednice Sjeverne Amerike (*engl. Radiological Society of North America - RSNA*). Skup podataka je stvoren s

ciljem organizacije natjecanja i sadrži otprilike oko 11 tisuća slika, dok prvi skup podataka sadrži oko 5.8 tisuća slika.

Oba skupa podataka su organizirani u tri direktorija: *train, val* i *test*, te je svaki od tih skupova podataka sadržavao direktorije *PNEUMONIA* i *NORMAL*. U direktoriju *NORMAL* su sadržane slike zdravih pluća, dok su kod *PNEUMONIA* sadržane snimke s bakterijskom ili virusom uzrokovanom upalom pluća. U sklopu ovog projekta implementiran je cjevovod podataka (*DataLoader*) s fiksnim paketima (engl. *batch size*) veličine od 32 uzorka. Tako se koriste tri seta: trening set (služi za optimizaciju parametara), validacijski set (služi za praćenje gubitka i metrika tijekom epoha te sprječavanje preučenja) i testni set (izolirani set snimki koji služi za finalnu objektivnu procjenu parametara odnosno performansi modela).

Proces treninga modela će se izvršiti na skupu podataka Radiološke zajednice Sjeverne Amerike. Detaljnijim uvidom i istraživanjem se daje zaključiti kako je taj skup podataka sličniji onim snimkama u stvarnim kliničkim i radiološkim okruženjima. A sama evaluacija modela izvršavat će se na dva skupa testnih podataka, kako bi se moglo pobliže odrediti stvarni odziv modela. Prvi spomenuti skup sadrži snimke koje su „čišće“ i lakše modelu za učenje.

Tijekom snimanja i spremanja rendgenskih slika iz više izvora, pogotovo ukoliko je prikupljen velik broj snimaka iz više različitih izvora, iste mogu biti u različitim rezolucijama i formatima. Iz tog razloga, a i kako bi se prilagodili arhitekturi konvolucijske mreže, implementirane su transformacije na skupu podataka. Kod promjene dimenzije sve slike se skaliraju na 224×224 piksela, čime se smanjuje računalna složenost uz zadržavanje kritičkih morfoloških struktura. Primjenjuje se također i nasumična rotacija do ±15° te afine transformacije – skaliranje u rasponu od 0.9 do 1.1 i translacija do 5%, čime se nastoje simulirati varijacije u pozicioniranju pacijenta ispred rendgenskog uređaja. Dodane su fotometrijske transformacije gdje se modificiraju svjetlina i kontrast kako bi model bio imuniji na tehničke razlike između različitih rendgenskih skenera. Dodatno se pridodaje i Gaussov šum. Jedno od augmentativnih tehnika koja se primjenjuje u projektu je i tehnika sakrivanja dijelova slike (generira se između 1 i 8 pravokutnih rupa veličine do 16×16 piksela). Ova metoda prisiljava mrežu da nauči kontekstualne značajke cijele regije pluća, umjesto da se fokusira samo na jednu specifičnu lokalnu točku. Za validacijske i testne podatke primjenjuje se isključivo *Resize* i *Normalize*, osiguravajući da se evaluacija vrši na autentičnim, neizmijenjenim medicinskim snimkama. Normalizacijom se vrijednosti piksela transformiraju na unaprijed definiranu distribuciju očekivanu od predtreniranog *EfficientNet-B0* modela, čime se stabilizira proces učenja. Cilj ovih postupaka je otežati učenje modela kako bi na validacijskim i testnim podacima mogao olakšano prepoznati relevantne značajke neovisno o manjim promjenama u položaju, veličini ili osvjetljenju objekata na slici. Augmentacijom se smanjuje rizik od prenaučenosti (*engl. overfitting*) i poboljšava sposobnost generalizacije na novim, prethodno neviđenim snimkama pluća.

3. Implementacija

U ovom poglavlju će biti opisana implementacija projektnog zadatka te će se nastojati opisati svi postupci koji su se proveli kako bi se došlo do modela. Kako bi se izbjeglo treniranje dubokih konvolucijskih neuronskih mreža skroz iz početka koriste se predtrenirani modeli. Takav model je onda potrebno prilagoditi zadatku koji rješavamo, odnosno potrebno je

prilagoditi posljednji sloj modela za vlastiti zadatak. Razvijeni model ovoga projekta temelji se na tom konceptu – prijenos znanja (*engl. Transfer learning*). Koristi se napredna neuronska mreža *EfficientNet-B0*, točnije odabrana je inačica predtrenirana metodom *Noisy Student*. Ova metoda koristi polu-nadgledano učenje na masivnim skupovima podataka, što rezultira robusnijim unutarnjim reprezentacijama i boljom generalizacijom na medicinskim slikama. Model je dizajniran modularno kako bi se omogućilo stupnjevito odmrzavanje slojeva. Izvorna klasifikacijska glava *EfficientNet* mreže u potpunosti je uklonjena. Nakon posljednjeg konvolucijskog bloka primjenjuje se globalno prosječno sažimanje kojim se prostorne dimenzije značajki svode na jednodimenzionalni vektor koji služi kao ulaz klasifikacijskoj glavi.

Nad tim je vektorom izgrađena prilagođena i klasifikacijska glava strukturirana kao sekvencijalni niz slojeva: dropout sloj, linearni sloj, ReLU aktivacijska funkcija, batch normalizacija, dropout sloj i na kraju linearni sloj.

Dropout slojevi imaju namjenu pri regularizaciji tako što nasumično postavljaju određen postotak ulaznih značajki na nulu. Batch normalizacija služi za normalizaciju skrivenog sloja unutar paketa (*engl. mini-batcha*) te tako stabilizira raspodjelu vrijednosti i ubrzava konvergenciju modela. *ReLU* aktivacijska funkcija uvodi nelinearnost u model. Zadnji linearni sloj svodi skrivenu aktivaciju na jedan izlazni neuron, koji je ujedno i krajnji rezultat modela. Kroz sve linearne module u glavi prolazi se petljom te se primjenjuje *Xavier Uniform* inicijalizacija za težine, dok se pomaci (*engl. biases*) postavljaju na nulu.

Skup podataka za trening pokazuje značajan klasni debalans jer je broj snimki s upalom pluća veći od broja zdravih pluća. Ako se taj problem ignorira, model može postati pristran prema većinskoj klasi. Za rješavanje ovog problema implementiran je dinamički izračun težinskog faktora pozitivne klase neposredno prije definiranja funkcije gubitka. Izračunati omjer koristi se kao parametar unutar funkcije gubitka. Time se pogreške na slabije zastupljenoj klasi dodatno penaliziraju, čime se smanjuje pristranost modela prema dominantnoj klasi.

U ovom projektu se kao funkcija gubitka koristi *BCEWithLogitsLoss()*. Ona kombinira logističku funkciju (*Sigmoid*) i binarnu unakrsnu entropiju. Implementacija funkcije smanjuje mogućnost pojave problema za vrlo velike ili vrlo male vrijednosti logita. Za optimizaciju parametara koristi se algoritam *AdamW*.

Ukoliko se želi postići da se određeni slojevi ne treniraju za vrijeme treninga, odnosno da se prebaci fokus na treniranje drugih slojeva neuronske mreže, koristi se zamrzavanje slojeva. Zamrzavanje slojeva se vrši na način da se slojevima koji se žele zamrznuti postavi vrijednost *requires_grad* na *False*. Za stabilno treniranje osjetljive medicinske mreže implementirana je troslojna strategija progresivnog odmrzavanja parametara kroz 20 epoha. Postupak se izvršava u tri faze:

U prve tri epohe se zamrzavaju svi parametri unutar *EfficientNet-a*. U ovoj fazi predtrenirane značajke ostaju netaknute, dok se nova klasifikacijska glava prilagođava domeni medicinskih slika.

Od četvrte do osme epohe posljednji konvolucijski blok postaje potpuno otvoren za učenje. Optimizator se redefinira s nižom, opreznijom stopom učenja $\eta = 1 \times 10^{-5}$ kako bi se visoki semantički slojevi fino uskladili s rendgenskim strukturama.

Od devete do dvadesete epohe se cijela mreža odmrzava, odnosno cijela postaje slobodna za učenje. Stopa učenja se smanjuje na $\eta = 5 \times 10^{-6}$ kako bi se preciznije pronašao globalni optimum performansi.

Radi učinkovitijeg korištenja grafičke kartice implementirano je treniranje mješovitom preciznošću. Tijekom izvođenja dio operacija izvršava se u 16-bitnoj preciznosti, dok se za numerički osjetljive operacije koristi 32-bitna preciznost. Time se smanjuje potrošnja memorije i ubrzava proces treniranja bez značajnog utjecaja na točnost modela.

Uvođenjem mehanizma ranog zaustavljanja sprječava se preučenje modela. U ovom projektu to je implementirano na način da je postavljen prag strpljenja od pet epoha. Ako validacijski gubitak ne ostvari poboljšanje u odnosu na prethodnu epohu, inkrementira se brojač promašenih epoha. Tijekom treniranja korišten je mehanizam automatske prilagodbe stope učenja *ReduceLROnPlateau*. *Scheduler* prati validacijski gubitak te u slučaju da tijekom dvije uzastopne epohe ne dođe do poboljšanja smanjuje stopu učenja za faktor 0.5. Na taj način omogućava se finije podešavanje parametara u kasnijim fazama treniranja i stabilnija konvergencija modela. Kada sve epohe treninga prođu ili brojač dosegne vrijednost praga strpljenja, trening se prekida, a najbolje stanje modela se pohranjuje. Model se prebacuje u evaluacijski način rada s isključenim praćenjem gradijenata.

Za razliku od standardnih računalnih klasifikatora koji koriste statični prag od 0.5, u ovom je sustavu implementiran stroži prag od 0.45 koji je pokazao najbolji rezultat nakon nekoliko pokušaja treniranja i evaluacije. Cilj prilagođavanja praga imao je većinsku ulogu u evaluacijskom dijelu, gdje će kasnije biti i opisan.

4. Evaluacija modela

Nakon završetka procesa treniranja i aktivacije mehanizma ranog zaustavljanja, iz memorije se učitava spremljene težine modela s najboljim rezultatima. Evaluacija je provedena na dva testna skupa, kako je već prethodno opisano u poglavlju *„Skup podataka i predobrada podataka“*. Time je osigurana maksimalna objektivnost i simulirani su stvarni klinički uvjeti u kojima sustav analizira nove pacijente.

Za sveobuhvatnu procjenu sposobnosti modela u prepoznavanju upale pluća, izračunato je pet standardnih metrika računalnog vida i medicinske dijagnostike uzimajući neke više u obzir od drugih.

Jedno od glavnih evaluacijskih sredstava kojima se može mjeriti uspješna predikcija modela je matrica zabune, koja ima četiri glavne evaluacijske vrijednosti.

Istinito pozitivne i istinito negativne vrijednosti matrice su bile one vrijednosti kojima se težilo istrenirati model, te povećati broj tih vrijednosti. Predstavljaju one vrijednosti koje je model uspio točno identificirati. Lažno pozitivne bile su vrijednosti matrice zabune koje se težilo smanjiti, a predstavlja one situacije kada model zdrave pacijente podvrgava bolesnima. Takav slučaj nije toliko loš koliko slučaj lažno negativnih vrijednosti gdje su bolesni pacijenti proglašeni bolesnima. Takav slučaj je najopasniji i on se nastojao najviše smanjiti tijekom treniranja i podešavanja praga odluke kod klasifikatora.

Točnost predstavlja ukupni dio točnih predikcija modela u odnosu na ukupan broj testiranih snimaka. Na ovu evaluacijsku vrijednost se ne može puno oslanjati i može zavaravati zbog klasnog debalansa.

Preciznost određuje koliki je udio stvarno bolesnih pacijenata među svim uzorcima koje je model klasificirao kao pozitivne. Visoka preciznost znači da model rijetko griješi u svojoj predikciji. Ova metrika je za potrebe ovog projekta imala veliku važnost.

Odziv (*engl. recall*) je predstavljen uspješno identificiranim snimkama bolesnika u odnosu na ukupan broj stvarno bolesnih snimaka u skupu. U medicinskoj praksi, odziv predstavlja najkritičniju metriku. Niski odziv implicira visoki broj lažno negativnih ishoda, što znači da sustav propušta bolesne pacijente i uskraćuje im pravovremeno liječenje, što izravno ugrožava ljudske živote.

F1-ocjena predstavlja harmonijsku sredinu preciznosti i odziva. Ona predstavlja mjeru uspješnosti modela, što je ključno za evaluaciju na neujednačenim skupovima podataka.

Kao što je implementirano u kodu, sustav koristi modificirani prag odluke prag 0.45. Standardni klasifikatori dodjeljuju pozitivnu klasu isključivo ako je izlazna vjerojatnost modela veća od 0.5. Međutim, u ovom je projektu prag svjesno pomaknut na 0.45. Ova odluka opravdana je kliničkom logikom upravljanja rizikom. Ako model analizira rendgensku snimku i izračuna vjerojatnost upale pluća od 47\%, standardni model bi tog pacijenta proglasio zdravim. S obzirom na suptilnost i preklapanje morfoloških znakova na rendgenu, to bi dovelo do kritične ljudsko-računalne pogreške. Spuštanjem praga na 0.45, model postaje senzibilniji na rane infiltrate i sumnjive sjene. Time se namjerno dopušta blago povećanje lažno pozitivnih rezultata kako bi se odziv maksimizirao, a lažno negativni rezultati sveli na apsolutni minimum. Za pacijenta je daleko sigurnije da bude upućen na dodatne pretrage uslijed lažne uzbune, nego da bude otpušten kući s nedijagnosticiranom upalom pluća.

4.1 Rezultati modela

Kao sami vrhunac projekta slijedi evaluacija i usporedba rezultata dvaju neuronskih mreža: EfficientNet-B0 i *VGG-16* predtreniranih neuronskih arhitektura.

EfficientNet-B0 je osnovna arhitektura EfficientNet obitelji. Razvijena je pomoću tehnologije pretraživanja arhitekture neuronskih mreža (*engl. Neural Architecture Search - NAS*) koja je optimizirala i točnost i računalnu učinkovitost (broj operacija s pomičnim zarezom - FLOPS). EfficientNet-B0 arhitektura ima oko 4 milijuna parametara, uzimajući u obzir da sama klasifikacijska glava osmišljena u projektu, ima otprilike 650 tisuća parametara. Sami treninzi po epohama nisu trajali dugo i nisu bili toliko računalno zahtjevni. Evaluacijom na testnom RSNA skupu ostvareni su vrhunski rezultati, koji pokazuju visoku pouzdanost modela.

- Gubitak (Loss): 0.0792
- Točnost (Accuracy): 97.27%
- Preciznost (Precision): 97.05%
- Odziv / Osjetljivost (Recall): 97.51%
- F1-ocjena (F1 Score): 97.28%

Kao što je već spomenuto, cilj optimiziranja konvolucijske neuronske mreže bio je povećati odziv, kako bi se što više utjecalo na FN veličinu u matrici zabune. Može se reći kako su sami rezultati vrlo dobri na novom skupu, uzimajući u obzir da je EfficientNet-B0 novija konvolucijska neuronska mreža. Matrica zabune može se vidjeti na Tablici 1.

	Predviđeno: NORMAL	Predviđeno: PNEUMONIA
Stvarno: NORMAL	**819**	**25**
Stvarno: PNEUMONIA	**21**	**823**

Tablica 1. Matrica zabune na
RSNA skupu podataka

Rezultati na RSNA skupu pokazuju izniman balans. Od 844 stvarna slučaja upale pluća, model je točno detektirao čak 823 uzorka (TP). Broj Lažno Negativnih (FN = 21) ishoda je izrazito nizak, što rezultira osjetljivošću od 97.51%. To znači da bi u kliničkom okruženju ovaj model propustio svega 2.49% bolesnih pacijenata. Nizak gubitak od 0.0792 i ujednačenost preciznosti i odziva (što potvrđuje visok F1-score od 0.9728) dokazuju da je RSNA skup podataka pružio konzistentne, jasne i dobro strukturirane morfološke značajke koje je EfficientNet-B0 uspješno generalizirao bez pojave preučenja (*overfittinga*).

Kaggle testni skup je dosta jednostavniji i jasniji u usporedbi s RSNA skupom. Model je na tom skupu ostvario sljedeće rezultate:

- Gubitak (Loss): 0.2906
- Točnost (Accuracy): 89.90%
- Preciznost (Precision): 86.74%
- Odziv / Osjetljivost (Recall): 98.97%
- F1-ocjena (F1 Score): 92.46%

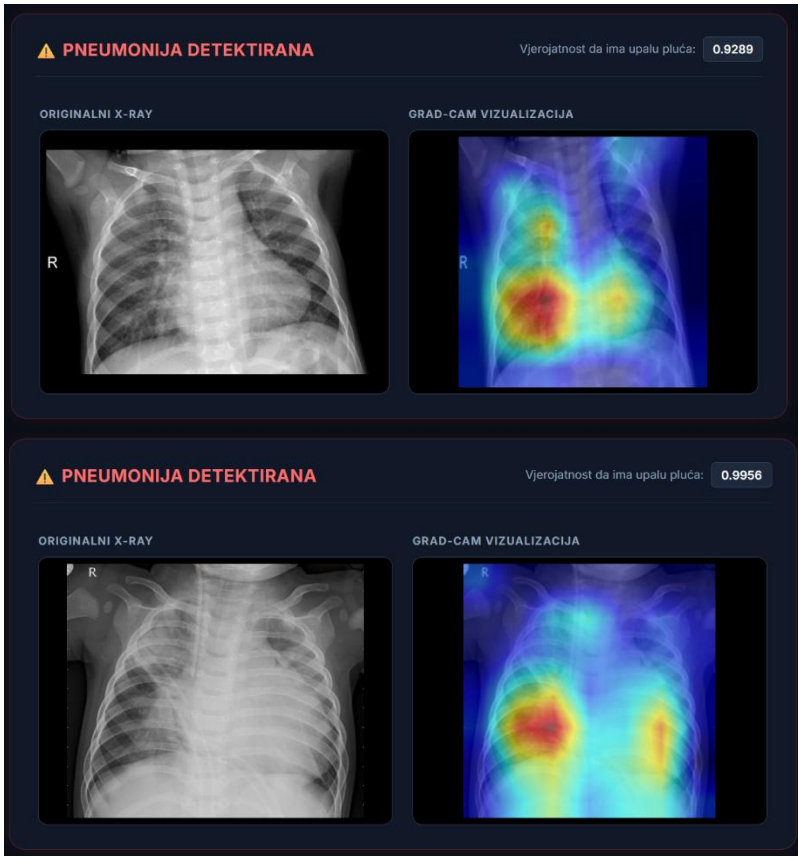
Primarna svrha evaluacije modela na drugom, potpuno neovisnom skupu podataka (u ovom slučaju *Kaggle* skupu) jest dobivanje realnijeg i objektivnijeg uvida u njegove performanse u stvarnim kliničkim uvjetima. Kada se konvolucijska neuronska mreža trenira i validira na jednom zatvorenom skupu podataka, uvijek postoji opravdana pretpostavka da je model razvio visoku točnost zbog specifičnih karakteristika tih slika. Ispitivanjem modela na posve novom i vanjskom skupu, koji sadrži drukčije morfološke varijacije, šumove i artefakte, eliminira se pristranost i izravno se testira sposobnost generalizacije mreže. Ovaj postupak simulira stvarni scenarij u kojem se aplikacija implementira u novu bolnicu i suočava s rendgenskim snimkama koje sustav nikada prije nije vidio, što je jedini pravi pokazatelj robusnosti i kliničke primjenjivosti razvijenog modela.

U usporedbi sa prethodnim skupom snimaka prsnog koša, na ovom su evaluacijski rezultati još bolji. Najvažnija metrika odziv pokazuje još bolji postotak uspješnosti. Preciznost je u usporedbi s prethodnim skupom podataka malo manja. To znači da je propušten nešto veći broj lažno pozitivnih. Detaljniji uvid nam daje Tablica 2. Problem malo većih lažno pozitivnih vrijednosti matrice zabune ne predstavlja toliko veliki problem u usporedbi s problemom lažno negativnih.

	Predviđeno: NORMAL	Predviđeno: PNEUMONIA
Stvarno: NORMAL	**175**	**59**
Stvarno: PNEUMONIA	**4**	**386**

Tablica 2. Matrica zabune na
Kaggle skupu podataka

Za sam kraj evaluacije i cjelokupnog prikaza rezultata konvolucijske neuronske mreže EfficientNet-B0, na slici 1. demonstriran je krajnji rezultat sustava uz popratnu interpretaciju prostornih aktivacija. Slika 1. ilustrira ne samo konačnu klasifikacijsku odluku, već i egzaktne anatomske regije unutar prsnog koša koje su potaknule model na donošenje te odluke, čime se pruža nužna transparentnost u radu algoritma. Međutim, detaljnijom i dubljom analizom kroz više desetaka testnih uzoraka, uočeni su i određeni nedostatci u kontekstu interpretatibilnosti. Zamijećeno je da mreža u pojedinim specifičnim slučajevima može donijeti ispravnu ili neispravnu odluku na temelju pogrešnih vizualnih premisa. Naime, kod manjeg broja snimki, *Grad-CAM* algoritam vizualizira žarišta visoke aktivacije na potpuno irelevantnim mjestima — poput samih uglova slika, artefakata na rubovima rendgenskog filma ili u regijama izvan samog tijela pacijenta gdje se nalazi čisti pozadinski prostor.



Slika 1. Konačni prikaz rezultata s
EfficientNet_b0

Kao drugi dio evaluacijskog dijela objasniti će se rezultati *VGG-16* konvolucijske arhitekture mreže. Prije analize važno je spomenuti kako je *VGG-16* starija neuronska mreža nastala 2015. godine i da sadržava 138 milijuna parametara. *VGG-16* predstavlja povijesnu prekretnicu u računalnom vidu zbog uvođenja homogene strukture s vrlo malim konvolucijskim filtrima poslaganim u duboke sekvencijalne blokove. Oslanja se na grubu dubinu i masivni kapacitet mreže. Zbog mnogo parametara sama implementacija i rad s neuronskom mrežom je bio otežan i vrlo spor. Stoga se morao smanjiti broj epoha, pomjeriti epohe smrzavanja slojeva neuronske mreže i u konačnici čak i promijeniti skup na kojem je mreža trenirana. Mreža je trenirana na *Kaggle* skupu podataka s ciljem bržeg izvođenja.

Na RSNA skupu za testiranje rezultati su sljedeći:

- Gubitak (Loss): 0.2228
- Točnost (Accuracy): 91.19%
- Preciznost (Precision): 90.36%
- Odziv / Osjetljivost (Recall): 96.15%
- F1-ocjena (F1 Score): 93.17%

Zahvaljujući svojoj dubokoj sekvencijalnoj strukturi, model je s visokom točnošću prepoznao jasne i izražene teksturalne oblike upale. Ostvarena preciznost iznosi 90.36%, dok je odziv zadržan na 96.15%. S obzirom da je mreža trenirana na manjem skupu podataka i uz manje epoha, može se zaključiti kako su rezultati vrlo dobri. Na Tablici 3. se može detaljnije vidjeti i matrica zabune:

	Predviđeno: NORMAL	Predviđeno: PNEUMONIA
Stvarno: NORMAL	**194**	**40**
Stvarno: PNEUMONIA	**15**	**375**

Tablica 3. Matrica zabune na
Kaggle skupu podataka

Visok odziv rezultira malim brojem lažno negativnih vrijednosti, što je bio cilj optimizacije i podešavanja praga odluke. Visoka F1-ocjena od 93.17% i relativno nizak gubitak (0.2228) dokazuju da na vizualno jednoznačnim i čišćim snimkama masivni kapacitet *VGG-16* mreže dolazi do punog izražaja. Kada je mreža bila testirana na drugom, RSNA skupu podataka, rezultati su očekivano bili malo lošiji, zbog same razlike u kvaliteti slika RSNA i *Kaggle* skupa.

- Gubitak (Loss): 0.3238
- Točnost (Accuracy): 82.41%
- Preciznost (Precision): 76.58%
- Odziv / Osjetljivost (Recall): 93.36%
- F1-ocjena (F1 Score): 84.14%

Evaluacijske vrijednosti poput točnosti i preciznosti su manje, ali sama vrijednost odziva ostaje iznad 90%, što bi moglo značiti da je neuronska mreža i dalje korisna u medicinskim okruženjima, ali bi dosta zdravih ljudi bilo proglašeno bolesnima. Detaljniju brojku se može vidjeti na Tablici 4.

	Predviđeno: NORMAL	Predviđeno: PNEUMONIA
Stvarno: NORMAL	**603**	**241**
Stvarno: PNEUMONIA	**56**	**788**

Tablica 4. Matrica zabune na
RSNA skupu podataka

Može se vidjeti kako vrijednost FP iznosi 241, što je ipak puno u odnosu na ukupna broj slika. Tolika vrijednost lažno pozitivnih slučaja je uzrokovala padom preciznosti. Model je ipak s više ukupnog gubitka donosio odluke.

U analizi prikaza *Grad-CAM*-a daje se zaključiti kako je *VGG-16* arhitektura puno bolje analizirala slike, jer su žarišta zbog kojih se donosila ipak relevantnija u odnosu na prethodne primjere kod *EfficientNet-B0*. Detaljniji prikaz je na Slici 2.



Slika 1. Konačni prikaz rezultata s
VGG-16

5. Demonstracija rada

Kao još jedan od zadataka ovog projekta bio je implementirati aplikaciju koja bi davala uvid u sve sto je spomenuto. Aplikacija je razvijena unutar programskog okruženja *Django*. Aplikacija je vrlo jednostavna i nije sučeljno zahtjevna za korisnika. Sučelje je podijeljeno u dva dijela: kontrolnu ploču za unos i prostor za prikaz rezultata.

Kada korisnik uđe u aplikaciju, prva mogućnost koju ima je prenijeti svoju snimku prsnog koša. Osim klasičnog prenošenja s računala, implementirana je i mogućnost drag-and-drop-a. Kada korisnik priloži sliku, aplikacija osvježava stranicu i korisniku dinamički generira završni dijagnostički prozor na kojem može vidjeti, ispisane konačne rezultate, normalnu sliku i *Grad-CAM* uvid, koji prikazuje područje od interesa. Slike se prikazuju neovisno o tome prikazuje li

slika bolesna ili zdrava pluća. U samom desnom uglu, iznad slika, nalazi se izračunata vjerojatnost da snimka pluća prikazuje zaražena pluća.

6. Zaključak

U sklopu ovog projekta uspješno je razvijen, istreniran i evaluiran napredni sustav računalnog vida namijenjen automatskoj detekciji upale pluća iz rendgenskih snimki prsnog koša. Primjenom metodologije dubokog učenja i koncepta prijenosa znanja (transfer learning) preko predtrenirane konvolucijske arhitekture *EfficientNet-B0*, premošteni su klasični izazovi rada s medicinskim slikovnim podacima, kao što su ograničena količina anotiranih uzoraka i visoka morfološka suptilnost patoloških promjena.

Kroz eksperimentalni rad potvrđeno je da troslojna strategija progresivnog odmrzavanja slojeva mreže – počevši od inicijalnog treniranja klasifikacijske glave, preko finog podešavanja zadnjeg konvolucijskog bloka, pa sve do globalne optimizacije cijele okosnice – rezultira iznimno stabilnom konvergencijom modela. Implementacija robusnih tehnika augmentacije podataka odigrala je ključnu ulogu u regularizaciji mreže, prisiljavajući je da nauči globalne značajke pluća umjesto pamćenja lokalnih značajki ili šuma specifičnog za pojedine rendgenske skenere.

Poseban doprinos ovog rada očituje se u prilagodbi sustava realnim kliničkim zahtjevima. Svjesnim pomicanjem praga klasifikacijske odluke na vrijednost 0.45, model je optimiziran za maksimizaciju odziva. Time je postignut primarni medicinski cilj: svođenje lažno negativnih rezultata na apsolutni minimum, čime se sprječava kritična pogreška propuštanja bolesnih pacijenata. Dodatno, integracijom algoritma *Grad-CAM* uspješno je riješen problem "crne kutije".

7. Literatura

[1] https://www.kaggle.com/competitions/rsna-pneumonia-detection-challenge/data

[2] https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia

[3] https://arxiv.org/abs/1905.11946

[4] https://arxiv.org/abs/1409.1556

[5] https://docs.pytorch.org/docs/2.12/nn.init.html#torch.nn.init.xavier_uniform_

[6] https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html

[7] https://docs.pytorch.org/docs/2.12/generated/torch.nn.BCEWithLogitsLoss.html

[8] https://docs.pytorch.org/docs/2.12/generated/torch.optim.AdamW.html

[9] https://poliklinika-mazalin.hr/blog/upala-pluca-sve-sto-trebate-znati/

[10] Materijali s kolegija Strojno učenje (predavanja, laboratorijske vježbe)

[11] GitHub repozitorij s cjelokupnim kodom: